

UNIVERSIDAD DEL VALLE DE GUATEMALA

Colegio Universitario



Laboratorio 10

Nombre de los integrantes del grupo:

Camila Richter - 23183

Marinés García - 23391

Esteban Cárcamo - 23016

Ian Cumes – 23236

Javier Valladares - 23045

Minería de Datos

Sección 10

15 mayo del 2026

Ciudad de Guatemala, Guatemala

1. Gaussian Mixture Models (GMM) Semi-Supervisados

Un Gaussian Mixture Model (GMM) modela la distribución de los datos como una combinación de K distribuciones gaussianas:

$$p(x) = \sum \pi_k N(x | \mu_k, \Sigma_k)$$

En el caso semi-supervisado, se combinan datos etiquetados y no etiquetados usando una función de log-verosimilitud conjunta.

1.1 Supuestos

- Mezcla de gaussianas multivariadas
- Independencia entre observaciones
- Missing At Random (MAR)
- Cada clase corresponde a un componente gaussiano

1.2 Algoritmo EM

Expectation-Maximization (EM) se usa para estimar los parámetros del modelo:

E-step: cálculo de responsabilidades (γ)
M-step: actualización de parámetros (μ , Σ , π)

En el caso semi-supervisado, las responsabilidades de los datos etiquetados se fijan según su clase real.

1.3 Tipo de aprendizaje

Este modelo es de tipo inductivo, ya que generaliza a nuevos datos.

1.4 Ventajas

- Aprovecha datos no etiquetados
- Modelo probabilístico interpretable
- Flexible en la forma de las distribuciones

1.5 Limitaciones

- Sensible a inicialización
- Problemas numéricos en covarianzas
- Supuesto gaussiano puede no cumplirse

2. Constrained K-Means

Constrained K-Means es una extensión del algoritmo K-Means que incorpora restricciones de conocimiento previo:

- Must-Link (ML): dos puntos deben pertenecer al mismo cluster
- Cannot-Link (CL): dos puntos no pueden pertenecer al mismo cluster

La función objetivo minimiza la distancia intra-cluster, respetando las restricciones impuestas.

2.1 Algoritmo COP-KMeans

El algoritmo asigna cada punto al cluster más cercano que no viole restricciones. Si no existe un cluster válido, el algoritmo puede fallar o reiniciar.

2.2 Tipo de aprendizaje

Es un método inductivo basado en clustering guiado.

2.3 Ventajas

- Integra conocimiento previo
- Mejora clustering con pocos datos etiquetados
- Fácil de implementar

2.4 Limitaciones

- Puede volverse infeasible con muchas restricciones
- Sensible a inicialización
- No es probabilístico

3. Tipos de variables y preprocesamiento

Los algoritmos requieren principalmente variables numéricas continuas. Las variables categóricas deben codificarse previamente.

- Se recomienda aplicar:
- Normalización (StandardScaler)
 - Codificación de variables categóricas
 - Reducción de dimensionalidad (PCA) para visualización

Impelentacion de modelos

Modelo	Accuracy
SupervisedBaseline GMM	0.8806
SupervisedBaseline RF	0.9028
SemiSupervisedGMM	0.8892
ConstrainedKMeans	0.7603

4. Conclusión

Los métodos semi-supervisados permiten aprovechar datos no etiquetados para mejorar el rendimiento cuando las etiquetas son escasas. GMM ofrece un enfoque probabilístico flexible, mientras que Constrained K-Means proporciona una alternativa más simple basada en restricciones.

Descarga dataset: <https://archive.ics.uci.edu/dataset/602/dry+bean+dataset>

Justificación del Dataset: Dry Bean Dataset (UCI)

El dataset Dry Bean Dataset fue seleccionado por su capacidad de manejo con los algoritmos asignados. El dataset contiene 13,611 observaciones de semillas de frijol de 7 variedades distintas (SEKER, BARBUNYA, BOMBAY, CALI, DERMASON, HOROZ, SIRA), caracterizadas por 16 variables continuas obtenidas por visión computacional, tales como área, perímetro, longitud de ejes, compacidad y excentricidad (Koklu & Ozkan, 2020).

GMM semi-supervisado

Los Modelos de Mezcla Gaussiana asumen que los datos de cada clase provienen de una distribución gaussiana multivariada. Las variables del dataset, presentan distribuciones aproximadamente normales, lo que satisface directamente el supuesto central del modelo. También,

la separabilidad entre clases observada en la proyección PCA 2D confirma que las gaussianas correspondientes a cada variedad ocupan regiones distinguibles en el espacio de características, condición favorable para que el algoritmo EM converja a una solución significativa. El escenario semi-supervisado es particularmente relevante aquí porque etiquetar semillas requiere expertos agrónomos, por lo que disponer de solo el 5–20% de etiquetas refleja una situación realista.

Constrained K-means.

Las 7 clases bien definidas del dataset permiten construir restricciones must-link y cannot-link directamente desde la fracción etiquetada: dos semillas de la misma variedad forman un par must-link, y dos semillas de variedades distintas forman un par cannot-link. El tamaño del dataset (13,611 filas) es suficiente para generar cientos de restricciones representativas sin saturar el algoritmo, y las 16 features continuas cumplen el requisito de normalización previa que exige la distancia euclidiana usada en K-means.

Fase 4 - Experimentacion

La experimentacion completa siguio el protocolo definido en la Fase 3: split 70/30 estratificado, simulacion semi-supervisada solo en train y test completamente etiquetado para evaluar generalizacion. Se ejecutaron tres modelos, tres fracciones etiquetadas (5%, 10% y 20%) y cinco semillas, para un total de 45 corridas en el experimento principal.

Los tres modelos comparados fueron: baseline supervisado con GMM, GMM semi-supervisado con EM y Constrained K-means con restricciones must-link/cannot-link. Las metricas reportadas fueron accuracy, F1-macro, recall-macro, tiempo de entrenamiento, accuracy de train y gap de generalizacion train-test.

Resultados del experimento principal

Modelo	5% acc test	10% acc test	20% acc test	Gap prom.
Baseline supervisado (GMM)	0.7793 +/- 0.0923	0.8262 +/- 0.0647	0.8002 +/- 0.0639	-0.0015
GMM semi-supervisado	0.8918 +/- 0.0072	0.8952 +/- 0.0065	0.9010 +/- 0.0073	-0.0025
Constrained K-means	0.8073 +/- 0.0320	0.7957 +/- 0.0041	0.8133 +/- 0.0286	-0.0001

El mejor desempeño promedio fue GMM semi-supervisado con 20% de etiquetas y accuracy promedio de 0.9010. En general, el GMM semi-supervisado domino las tres fracciones, llegando a 0.9010 de accuracy promedio con 20% de etiquetas. Esto indica que el EM con datos no etiquetados aprovecho mejor la estructura continua del dataset que el baseline supervisado y que CKM.

El baseline supervisado fue el mas variable porque depende solo de las etiquetas visibles. Con 5% de etiquetas tuvo desviacion estandar de 0.0923, mientras que el GMM semi-supervisado tuvo 0.0072. Esto muestra que el metodo semi-supervisado fue mas estable entre semillas.

Diagnostico de overfitting y underfitting


No se observo overfitting fuerte. Los gaps promedio train-test fueron cercanos a cero para todos los modelos y fracciones. Si hubiera overfitting, train_accuracy seria mucho mayor que accuracy de test. Tampoco hay underfitting severo en GMM semi-supervisado, porque train y test se mantienen altos; el menor desempeno de CKM y del baseline se explica mas por limitaciones del modelo que por una brecha train-test.

Sensibilidad de GMM semi-supervisado

Para GMM se fijo 10% etiquetado y se variaron covariance_type en {full, tied, diag, spherical} y reg_covar en {1e-6, 1e-4, 1e-2}, con tres semillas por configuracion. La mejor configuracion fue covariance_type=full y reg_covar=1e-2, con accuracy promedio de 0.9092.

covariance_type	reg_covar	Accuracy test	F1-macro	Gap
full	1e-02	0.9092 +/- 0.0051	0.9224	-0.0041
full	1e-04	0.8961 +/- 0.0053	0.9124	-0.0070
full	1e-06	0.8922 +/- 0.0048	0.9072	-0.0064
diag	1e-02	0.8810 +/- 0.0049	0.8879	-0.0045
diag	1e-04	0.8783 +/- 0.0038	0.8850	-0.0043
diag	1e-06	0.8781 +/- 0.0042	0.8848	-0.0042

La covarianza full fue la mas efectiva porque permite modelar correlaciones entre las 16 variables. Las opciones diag y spherical fueron mas restrictivas, y tied fue la mas debil porque fuerza una sola forma de covarianza para todas las clases. Aumentar reg_covar a 1e-2 estabilizo la estimacion y mejoro la generalizacion.




Sensibilidad de Constrained K-means

Para Constrained K-means se fijo 10% etiquetado y se vario max_constraints en {50, 200, 500, 1000}. En esta implementacion, max_constraints=N significa usar hasta N restricciones must-link y N restricciones cannot-link.

max_constraints	Accuracy test	F1-macro	Gap
50	0.7992 +/- 0.0016	0.7401	-0.0024
200	0.7913 +/- 0.0049	0.7714	-0.0049
500	0.7971 +/- 0.0049	0.7825	-0.0043
1000	0.7997 +/- 0.0039	0.7870	-0.0039


El accuracy de CKM se mantuvo alrededor de 0.79-0.80 y no aumento de forma monotona con mas restricciones. Sin embargo, el F1-macro mejoro al aumentar restricciones, lo que sugiere una mejor distribucion por clase. Aun asi, CKM quedo por debajo de GMM semi-supervisado porque depende de distancia euclidiana y clusters aproximadamente esfericos.




Fase 5 - Visualización y discusión crítica

Las curvas de desempeño permiten comparar el comportamiento de los modelos conforme aumenta el porcentaje de datos etiquetados. Se analizaron los escenarios de 5%, 10% y 20% de etiquetas, comparando el baseline supervisado, el GMM semi-supervisado y Constrained K-means.

Los resultados muestran que el GMM semi-supervisado obtuvo el mejor desempeño general. Con 5% de etiquetas alcanzó un accuracy promedio de 0.8918, con 10% obtuvo 0.8952 y con 20% llegó a 0.9010. En comparación, el baseline supervisado obtuvo 0.7793, 0.8262 y 0.8002 respectivamente. Esto indica que el modelo semi-supervisado aprovechó mejor la información de los datos no etiquetados, especialmente cuando la cantidad de etiquetas disponibles era baja.




El F1-macro confirma la misma tendencia. El GMM semi-supervisado mantuvo valores altos y estables, lo cual indica que su buen desempeño no se concentró únicamente en las clases mayoritarias, sino que logró un rendimiento más balanceado entre las diferentes variedades de frijol.




Matrices de confusión

Las matrices de confusión permiten analizar los errores cometidos por cada modelo. En el escenario con 10% de datos etiquetados, el GMM semi-supervisado presenta una diagonal principal más marcada, lo cual indica una mayor cantidad de clasificaciones correctas. El baseline supervisado muestra más confusiones porque aprende únicamente a partir de una fracción pequeña de etiquetas. Constrained K-means tiene un comportamiento intermedio, ya que utiliza restricciones must-link y cannot-link, pero depende de que estas restricciones representen adecuadamente la estructura real de los datos.



Evolución del log-likelihood


La evolución del log-likelihood permite observar el proceso de convergencia del algoritmo EM utilizado en el GMM semi-supervisado. Un aumento progresivo del log-likelihood indica que el modelo mejora su ajuste a los datos en cada iteración. Esta gráfica es importante porque permite verificar que el entrenamiento no se detuvo de forma arbitraria, sino que siguió un proceso de optimización estable.



Visualización PCA


La visualización mediante PCA reduce las 16 variables originales a dos componentes principales, permitiendo observar la distribución general de las clases. En la proyección se observa que algunas variedades de frijol tienen regiones relativamente separables, mientras que otras presentan traslape. Esto explica por qué ciertos modelos cometen errores entre clases con características morfológicas similares.

Al comparar las predicciones de los modelos, el GMM semi-supervisado conserva mejor la estructura general de las clases reales. Constrained K-means puede generar agrupaciones menos precisas cuando las clases no tienen una forma esférica o cuando las fronteras entre grupos son difusas.




Estabilidad entre semillas

El boxplot de accuracy entre semillas permite evaluar qué tan estable fue cada modelo ante diferentes selecciones aleatorias de datos etiquetados. El GMM semi-supervisado fue el modelo más estable, ya que mantuvo una desviación estándar baja en los tres escenarios. Con 5% de etiquetas tuvo una desviación estándar de 0.0072, mientras que el baseline supervisado tuvo 0.0923. Esto demuestra que el baseline depende más de cuáles ejemplos etiquetados se seleccionan, mientras que el modelo semi-supervisado es más robusto porque también utiliza la estructura de los datos no etiquetados.



Comparación entre train y test

La comparación entre accuracy de entrenamiento y accuracy de prueba permite identificar posibles problemas de overfitting o underfitting. En los resultados obtenidos no se observa overfitting fuerte, ya que los valores de train y test se mantienen cercanos. En el caso del GMM semi-supervisado, el desempeño alto y la baja diferencia entre entrenamiento y prueba indican que el modelo generaliza adecuadamente.



Discusión crítica

Los resultados muestran que el aprendizaje semi-supervisado sí aportó valor frente al baseline supervisado. El mejor modelo fue el GMM semi-supervisado, ya que obtuvo el mayor accuracy, el mejor F1-macro y la menor variabilidad entre semillas. Esto se debe a que el modelo no depende únicamente de las etiquetas disponibles, sino que también aprovecha la distribución de los datos no etiquetados durante el proceso de estimación.

El mayor beneficio del enfoque semi-supervisado se observa cuando hay pocas etiquetas disponibles. Con solo 5% de datos etiquetados, el GMM semi-supervisado superó claramente al baseline, lo que demuestra que este tipo de modelo es útil cuando etiquetar datos es costoso o limitado.

Constrained K-means también incorpora información supervisada mediante restricciones, pero su desempeño fue menos consistente. Esto se debe a que el algoritmo depende de la calidad de las restricciones y de la forma geométrica de los clusters. Si las clases tienen

traslape o no son aproximadamente esféricas, el modelo puede confundir observaciones de clases similares.

En conclusión, el GMM semi-supervisado fue el enfoque más sólido para este dataset. Su capacidad de combinar etiquetas parciales con la estructura de los datos no etiquetados le permitió superar al modelo supervisado puro y mantener un desempeño estable en los tres porcentajes evaluados.

Referencias

Koklu, M., & Ozkan, I. A. (2020). Multiclass classification of dry beans using computer vision and machine learning techniques. *Computers and Electronics in Agriculture*, 174, 105507. <https://doi.org/10.1016/j.compag.2020.105507>

Bishop, C. M. (2006). Pattern Recognition and Machine Learning.

Wagstaff, K. et al. (2001). Constrained K-Means Clustering.

Murphy, K. P. (2012). Machine Learning: A Probabilistic Perspective.